FRAUDCLOUD 2026

DISEÑO E IMPLEMENTACIÓN DE UN PIPELINE DE BIG DATA EN AWS PARA EL ANÁLISIS DE FRAUDE CON TARJETAS DE CRÉDITO



ENTREGA	EVIDENCIA REAL	ALCANCE
Trabajo integrador	S3 → Glue → Data Catalog → Athena	Reporte técnico, resultados y seguridad
Fecha de implementación	04/11/2026 · us-east-1	Sustentación: 18 y 19/11/2026
Estado del proyecto	Pipeline desplegado y probado	El panel Streamlit funciona localmente

Documento académico con capturas seleccionadas. Se excluyeron duplicados, errores transitorios, recursos ajenos al pipeline y pantallas personales no pertinentes.

1. Resumen ejecutivo y alcance

FraudCloud 2026 implementó un pipeline reproducible en Amazon Web Services para procesar un CSV de transacciones etiquetadas, transformarlo a Parquet y responder preguntas de negocio mediante SQL. La solución fue desplegada realmente, a diferencia de la versión preliminar del documento, que describía solo la preparación local.

INDICADOR VALIDADO	RESULTADO
Registros analizados	339 607
Etiquetas fraudulentas	1 782
Operaciones legítimas	337 825
Tasa de fraude global	0,5247 %
Variables en CSV aportado	19
Filas válidas / rechazadas	339 607 / 0
Consultas SQL demostradas en Athena	3 completadas (de 8 scripts disponibles)

Alcance de las evidencias

El informe presenta evidencias del stack CREATE_COMPLETE, archivos Parquet en S3, ejecución Glue SUCCEEDED y Crawler READY, tres consultas Athena con resultados y dashboard Streamlit con CSV exportados de Athena. Costos y presupuestos se analizan a nivel de cuenta, por lo que no se atribuyen gastos de laboratorios antiguos al pipeline.

Control de calidad de la selección

Se utilizaron únicamente capturas pertinentes, no duplicadas y con información verificable. No se incorporaron imágenes de plataformas educativas, sesiones fallidas de acceso, errores de bucket ya resueltos ni recursos EC2/RDS/NAT como componentes de la solución.

2. Contexto, problema y descripción de los datos

El fraude en operaciones electrónicas requiere identificar patrones observables para orientar supervisión y priorización de revisiones. El objetivo de este trabajo es describir la incidencia del fraude por horario y bandera de riesgo, sin afirmar relaciones causales ni presentar resultados como un modelo predictivo.

ATRIBUTO	VALOR / CONSIDERACIÓN
Archivo de entrada	fraude_tarjeta_credito_process.csv
Registros	339 607 filas; 19 columnas
Variable objetivo	es_fraude (0=legítima; 1=fraude)
Variables de segmentación	es_noche; high_risk_cat; edad_grupo; mes; día
Montos	monto_winsorizado_99: transformado, no pérdida monetaria real
Datos de origen	CSV procesado proporcionado por el usuario; referencia declarada a Kaggle
Limitaciones	Sin identificador completo de transacción, fecha/año, moneda ni categoría comercial descriptiva

Pregunta de negocio y enfoque analítico

¿Qué proporción de transacciones resulta fraudulenta en la muestra y cómo varía entre operaciones nocturnas y operaciones marcadas con high_risk_cat? Se calculan tasas dentro de cada grupo para evitar comparar únicamente cantidades en un dataset altamente desbalanceado.

Reproducibilidad

La validación local reportó 339 607 registros válidos, 0 inválidos, 1 782 fraudes, tasa 0,5247 %. Se conserva el CSV RAW; la transformación aplica selección y tipado de campos y escribe la zona CURATED en formato Parquet con compresión Snappy.

3. Arquitectura AWS implementada



Figura A. Diagrama de arquitectura del proyecto. Fuente: diagrama editable incluido en el proyecto.

ETAPA	SERVICIO	FUNCIÓN
Despliegue	CloudFormation	Crea infraestructura reproducible
Ingesta	Amazon S3 RAW	Almacena el CSV fuente
Transformación	AWS Glue ETL	Valida filas y genera Parquet
Analítica	S3 CURATED + Glue Crawler	Conserva Parquet, crea particiones y tabla
Consulta	Amazon Athena	SQL sobre transacciones
Presentación	Streamlit local	Visualiza resultados exportados de Athena
Control	IAM + Budgets	Accesos, cifrado y alertas de costos

Nota: Streamlit se ejecutó en la computadora del estudiante (localhost:8501); las capturas no prueban que el dashboard esté alojado públicamente en AWS.

4. Implementación: infraestructura y almacenamiento

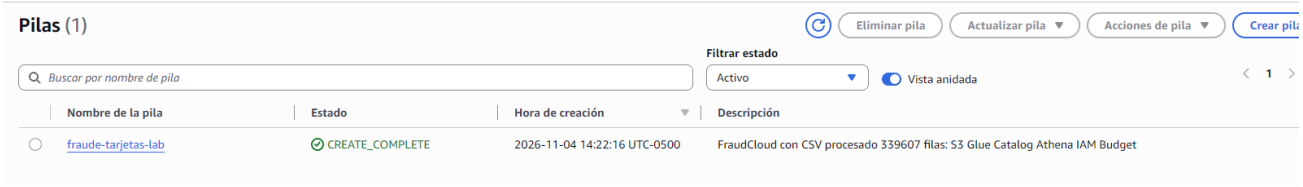


Figura 1. CloudFormation confirma CREATE_COMPLETE para el stack académico. Fuente: captura real de AWS / ejecución aportada, 04-11-2026.

La pila fraude-tarjetas-lab fue creada correctamente en Norte de Virginia (us-east-1) el 04/11/2026. La plantilla define el bucket privado, base Glue, rol de servicio, trabajo ETL, crawler, workgroup Athena y presupuesto.

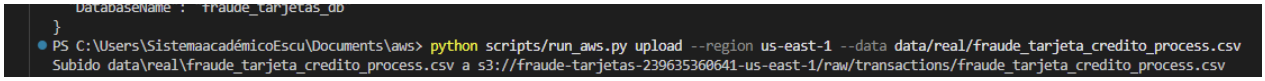


Figura 2. Script de ingestión confirma la carga de CSV a la zona RAW. Fuente: captura real de AWS / ejecución aportada, 04-11-2026.

El archivo original se conserva en raw/transactions/. Esta captura muestra la salida de subida del script y no constituye por sí sola una verificación del contenido de cada registro.

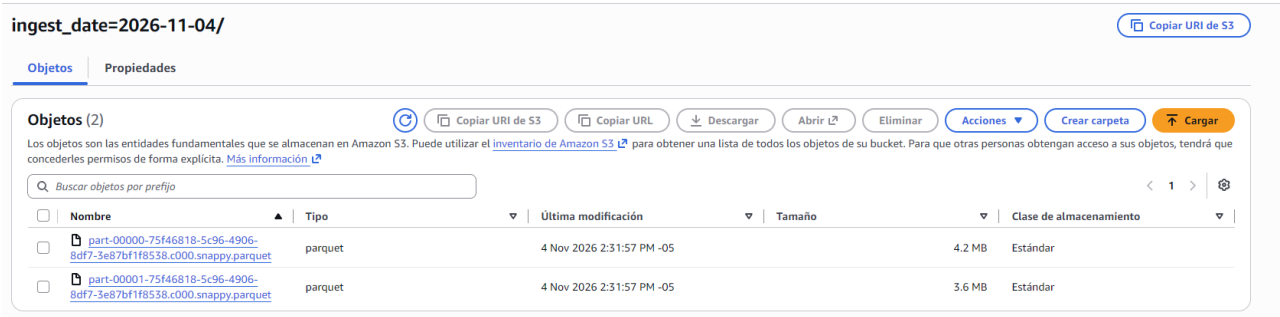


Figura 3. Parquet Snappy registrado bajo curated/transactions/ingest_date=2026-11-04. Fuente: captura real de AWS / ejecución aportada, 04-11-2026.

Se observan dos objetos de aproximadamente 4,2 MB y 3,6 MB. La zona CURATED aprovecha almacenamiento columnar y particionado por fecha de ingesta.

4.1. Transformación ETL y catálogo Glue

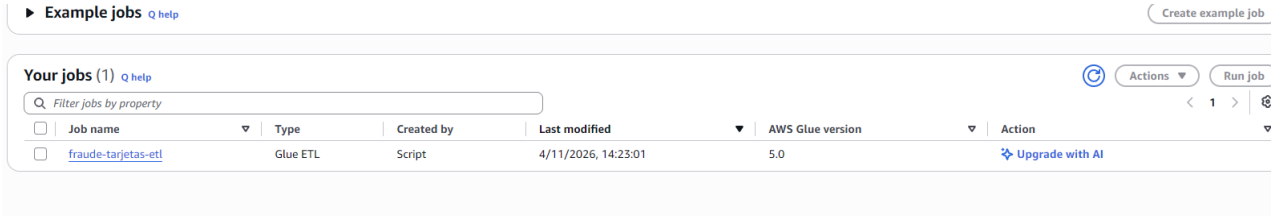


Figura 4. Trabajo de ETL registrado en la consola Glue. Fuente: captura real de AWS / ejecución aportada, 04-11-2026.

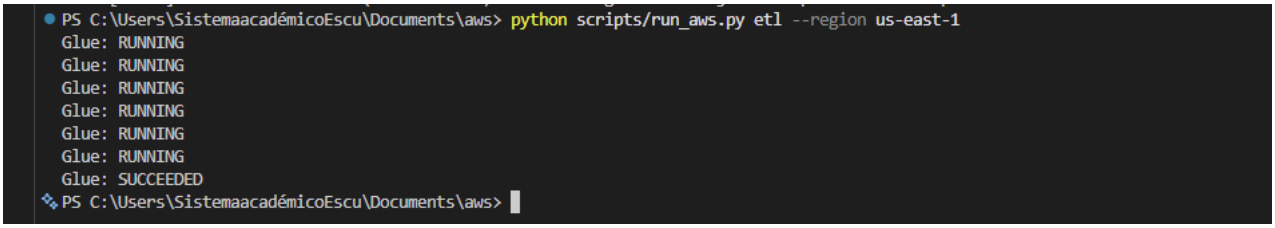


Figura 5. Ejecución del comando ETL concluida con estado SUCCEEDED. Fuente: captura real de AWS / ejecución aportada, 04-11-2026.

El job AWS Glue 5.0 fue creado para convertir el CSV procesado a Parquet Snappy. El comando muestra SUCCEEDED; la captura de la consola confirma la existencia del job. Se evita confundir existencia de un recurso con resultado exitoso de una ejecución.

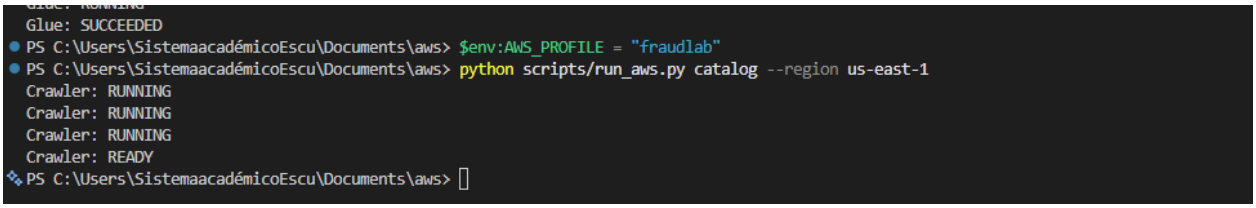


Figura 6. Crawler finaliza y regresa a estado READY. Fuente: captura real de AWS / ejecución aportada, 04-11-2026.

El crawler catalogó los datos transformados en fraude_tarjetas_db, tabla fraud_transactions. Las consultas que siguen demuestran que la tabla resultante fue consultable desde Amazon Athena.

5. Consultas SQL verificadas en Athena

Las tres consultas seleccionadas son diferentes, reproducibles y responden preguntas de negocio: volumen/tasa global, comparación nocturna y comparación por indicador de alto riesgo. Cada una fue ejecutada en el catálogo y aparece con estado Completado.

5.1. Consulta 1 — tasa global de fraude

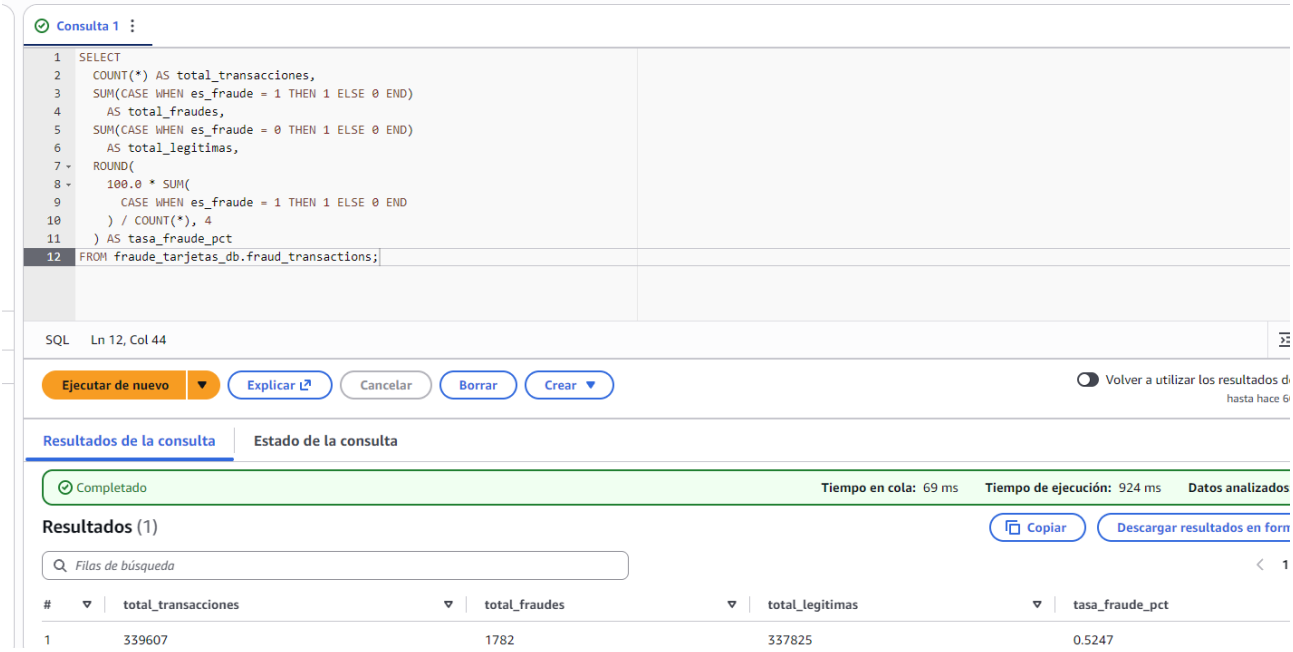


Figura 7. Consulta SQL completa y resultados globales en Athena. Fuente: captura real de AWS / ejecución aportada, 04-11-2026.

MÉTRICA	RESULTADO
Transacciones	339 607
Fraudes	1 782
Legítimas	337 825
Tasa de fraude	0,5247 %

Interpretación: de cada 1 000 transacciones del conjunto, aproximadamente 5,25 estaban etiquetadas como fraudulentas. El gran desbalance de clases obliga a comparar tasas por segmento.

5.2. Consulta 2 — fraude según horario nocturno

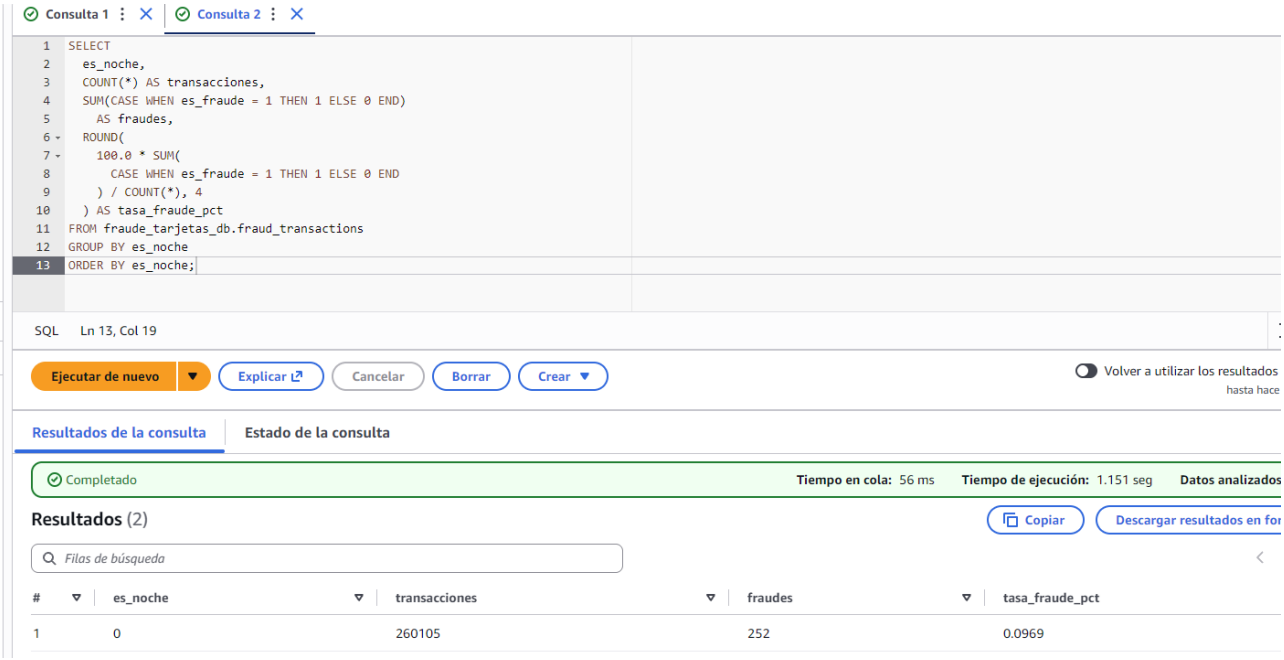


Figura 8. Agrupación SQL según es_noche y tasas observadas. Fuente: captura real de AWS / ejecución aportada, 04-11-2026.

GRUPO	TRANSACCIONES	FRAUDES	TASA
No nocturno (0)	260 105	252	0,0969 %
Nocturno (1)	79 502	1 530	1,9245 %

Interpretación: la tasa observada durante la noche es unas 19,9 veces la no nocturna. Es una asociación descriptiva dentro de este CSV; no prueba causalidad ni establece por sí sola una regla de bloqueo automático.

Recomendación analítica

Revisar las transacciones nocturnas junto con señales adicionales y controlar la tasa de falsos positivos. El conjunto de datos no incluye datos suficientes para evaluar un modelo predictivo en producción.

5.3. Consulta 3 — indicador de categoría de riesgo

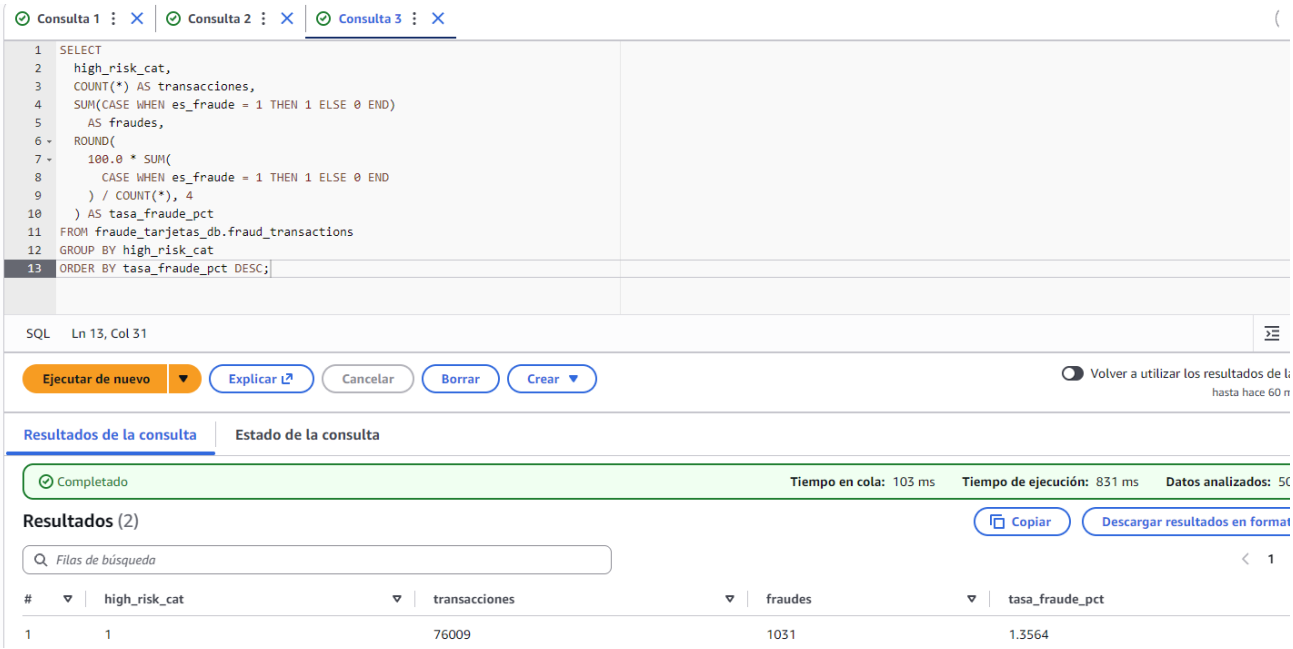


Figura 9. Agrupación SQL según high_risk_cat y tasas observadas. Fuente: captura real de AWS / ejecución aportada, 04-11-2026.

GRUPO	TRANSACCIONES	FRAUDES	TASA
Marca de riesgo (1)	76 009	1 031	1,3564 %
Sin marca (0)	263 598	751	0,2849 %

Interpretación: el grupo marcado como riesgo alto presenta una tasa aproximadamente 4,8 veces mayor. high_risk_cat es una bandera binaria; el CSV no permite identificar comercios específicos. No se debe presentar esta etiqueta como categoría comercial textual.

6. Dashboard y presentación de los resultados

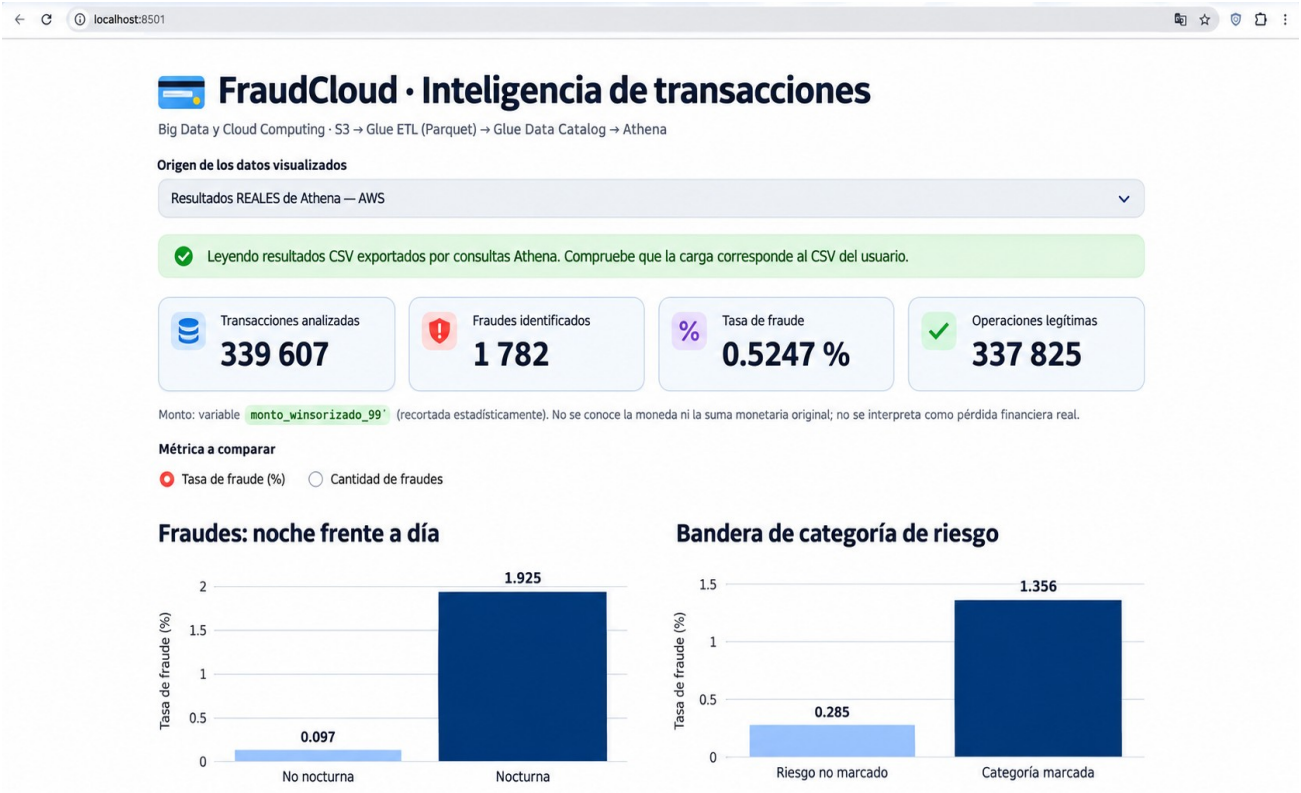


Figura 10. Dashboard FraudCloud consumiendo archivos de resultados de Athena. Fuente: captura real de AWS / ejecución aportada, 04-11-2026.

La vista mostrada desde localhost:8501 permite alternar indicadores y comparar las tasas de fraude por horario y bandera de riesgo. El mensaje “Resultados REALES de Athena - AWS” corresponde a la lectura de los CSV exportados por las consultas, no a una conexión continua a Athena en cada interacción.

Indicadores de negocio

INDICADOR	DEFINICIÓN
Volumen	Número total de transacciones procesadas
Fraudes	Operaciones con es_fraude=1
Tasa global	Fraudes / total × 100
Nocturno vs no nocturno	Tasa de fraude dentro de es_noche=1 o 0
Riesgo alto vs sin marca	Tasa dentro de high_risk_cat=1 o 0

Se evita presentar monto_winsorizado_99 como importe original o pérdida económica, dado que se trata de una transformación estadística de la variable.

7. Costos observados, calculadora y presupuestos en AWS

7.1. Evidencia del presupuesto

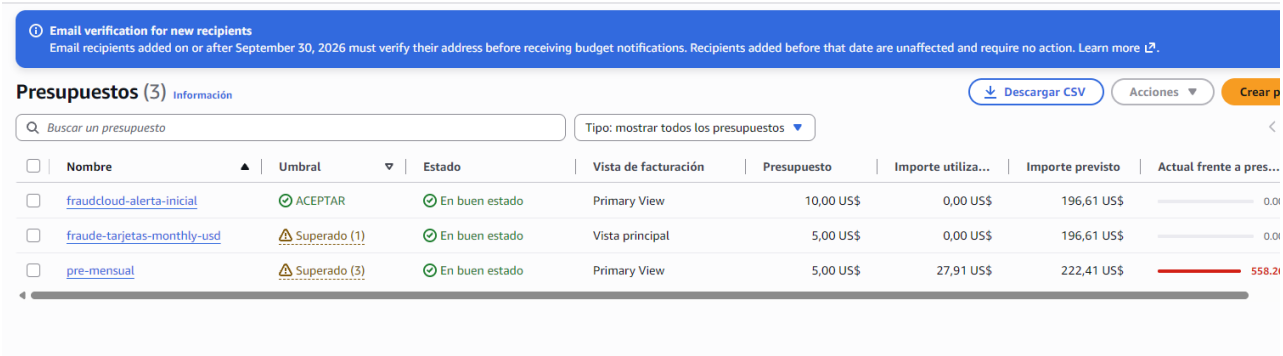


Figura 11. Presupuestos de la cuenta, incluido el creado para FraudCloud. Fuente: captura real de AWS / ejecución aportada, 04-11-2026.

El presupuesto fraude-tarjetas-monthly-usd figura con límite US$ 5,00 y gasto observado US$ 0,00 en la captura. El presupuesto general pre-mensual muestra US$ 27,91 para noviembre. Estos valores tienen alcances distintos. El presupuesto es una alerta y no un límite automático de gasto; la estimación del CSV se analiza en el apartado 7.5.

7.2. Evidencia de la factura



Figura 12. Factura de noviembre, estimación neta mostrada US$ 0,00. Fuente: captura real de AWS / ejecución aportada, 04-11-2026.

La vista de factura aparece con total neto US$ 0,00 (pendiente), pero no equivale a ausencia de uso. En el detalle de cargos se identificaron créditos que compensan el consumo de EC2, RDS y VPC, recursos de laboratorios anteriores.

7.3. Conciliación de consumo, créditos y recursos ajenos

SERVICIO DE LA CUENTA	CONSUMO ANTES DE CRÉDITOS	CRÉDITOS
EC2, NAT Gateway, EBS	US$ 18,00	−US$ 18,00
RDS	US$ 5,81	−US$ 5,81
VPC / IPv4 públicas	US$ 4,08	−US$ 4,08
TOTAL IDENTIFICADO	US$ 27,89	−US$ 27,89

El importe neto de noviembre se muestra en US$ 0,00; la diferencia aproximada de US$ 0,02 respecto de pre-mensual (US$ 27,91) puede responder a redondeos, filtros o tiempos de actualización y no se atribuye al pipeline. La suma de la factura de cuenta antes de créditos NO constituye el costo exclusivo de FraudCloud.

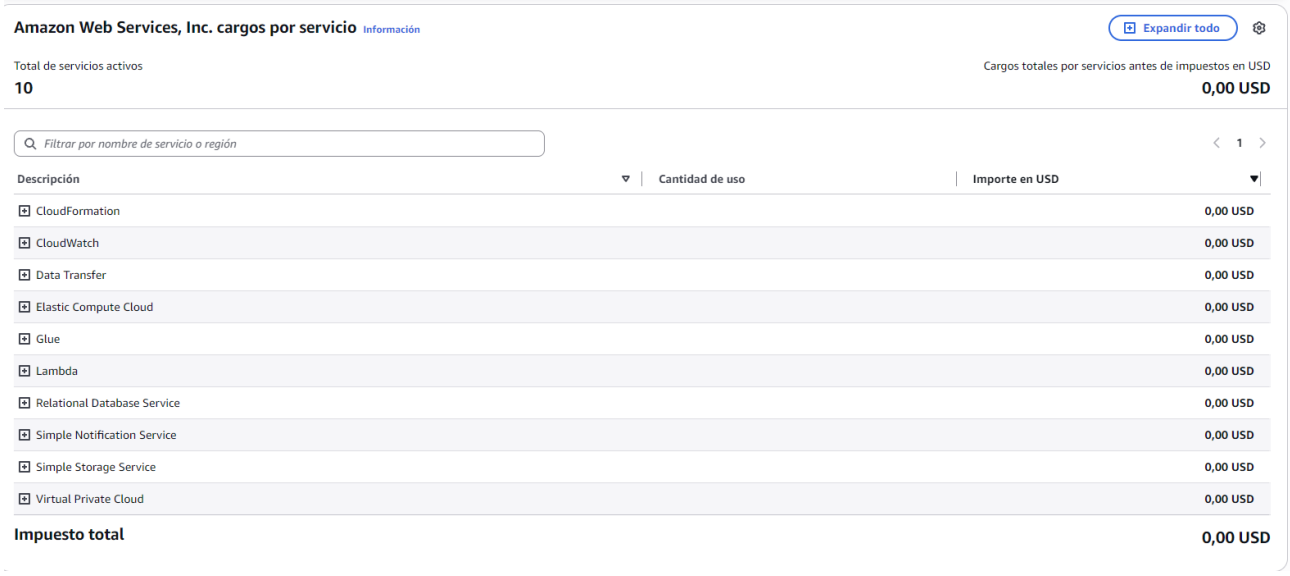


Figura 13. Desglose de facturación neta por servicios en AWS Bills. Fuente: captura real de AWS / ejecución aportada, 04-11-2026.

7.4. Cost Explorer: vista de costos netos

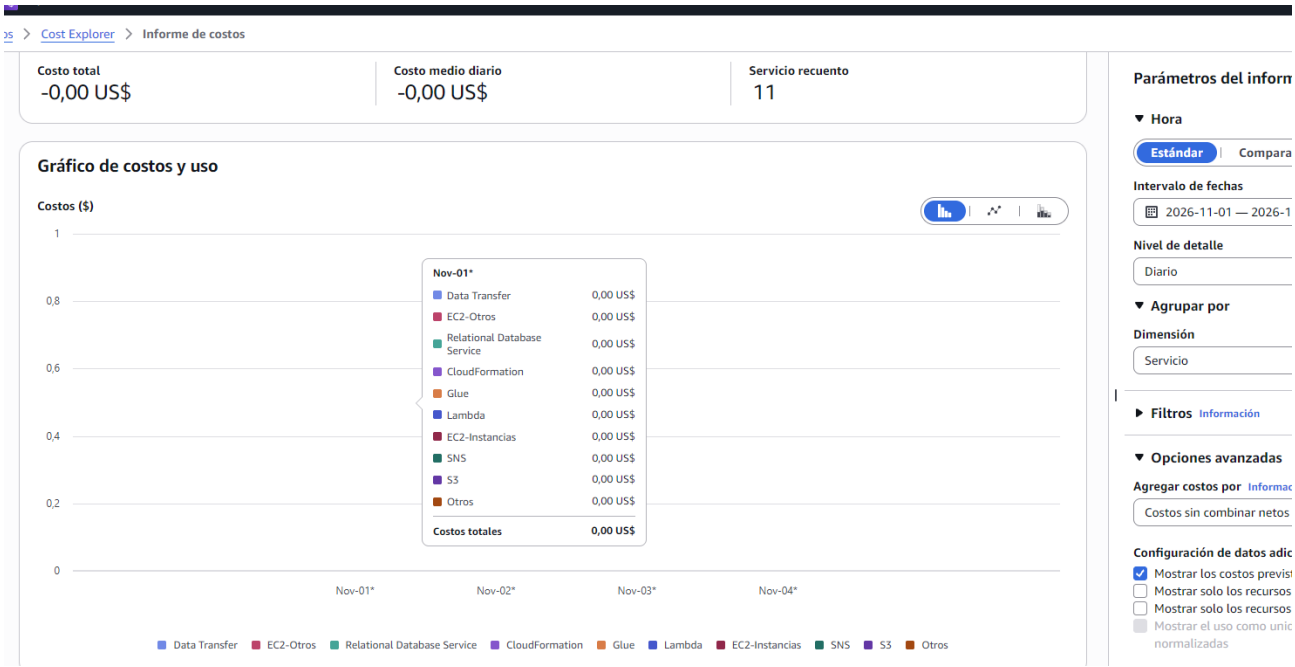


Figura 14. Costo neto visualizado para el periodo consultado, próximo a US$ 0,00. Fuente: captura real de AWS / ejecución aportada, 04-11-2026.

7.5. Estimación documentada con AWS Pricing Calculator

Fuente verificada: archivo CSV exportado de la estimación “FraudCloud”, el 04/11/2026 a las 17:00 (UTC-5). El registro declara 8 líneas de consumo, región us-east-1, estado VALID y tarifas BEFORE_DISCOUNTS (antes de descuentos). Los importes corresponden al escenario configurado en la calculadora, NO a una factura ni a un consumo medido en la cuenta.

Resumen del costo modelado por servicio

Servicio	Importe estimado (USD)	Participación
AWS Glue	5,280000000	99,84 %
Amazon Athena	0,004882813	0,09 %
Amazon S3	0,003505000	0,07 %
TOTAL (8 líneas)	5,288387813	100,00 %

Total redondeado para presentación: US$ 5,29. AWS Glue concentra aproximadamente el 99,84 % del importe modelado.

Trazabilidad: las 8 líneas del CSV

Servicio	Uso modelado	Costo USD
Glue	ETL Gen2 (10 DPU-h)	3,080000000
Glue	Endpoint de desarrollo (5 DPU-h)	2,200000000
Athena	Datos escaneados (0,000976563 TB)	0,004882813
S3	Almacenamiento Standard (0,1 GB-mes)	0,002300000
S3	Solicitudes Tier1 (107)	0,000535000
S3	Solicitudes Tier2 (1000)	0,000400000
S3	S3 Select: datos escaneados (0,1 GB)	0,000200000
S3	S3 Select: datos devueltos (0,1 GB)	0,000070000

Nota técnica: los costos pequeños se muestran con nueve decimales para evitar que el redondeo a US$ 0,00 oculte uso estimado. El cálculo total procede directamente de la suma de las columnas item/costSummary/cost del CSV.

Lectura financiera y control del presupuesto

Si esta misma carga se facturara bajo las condiciones del CSV, el costo previsto (US$ 5,29) superaría en US$ 0,29 (+5,77 %) la referencia de US$ 5,00 mostrada en un presupuesto de la cuenta. La comparación es orientativa: la calculadora proyecta una carga de trabajo antes de descuentos, mientras que AWS Budgets y Bills reflejan consumo y facturación con otros alcances, filtros, períodos y posibles créditos. Un presupuesto no bloquea automáticamente la ejecución de recursos.

7.6. Proyección académica adicional (escenarios)

Este ejercicio es una proyección hipotética independiente de la estimación exportada desde AWS Pricing Calculator (apartado 7.5). No representa consumo facturado ni un presupuesto vinculante. Los supuestos de 8 y 30 ciclos mensuales permiten discutir la sensibilidad del costo al crecimiento de las ejecuciones. No deben sumarse a la estimación del CSV.

SUPUESTO	BAJO: 8 CICLOS/MES	MAYOR: 30 CICLOS/MES
Glue ETL (2 DPU × 10 min / ciclo)	≈ US$ 1,17	≈ US$ 4,40
Glue Crawler (1 DPU × 10 min / ciclo)	≈ US$ 0,59	≈ US$ 2,20
S3 Standard (0,1 GB / 0,3 GB)	≈ US$ 0,002	≈ US$ 0,007
Athena (80/300 consultas de 10 MB)	≈ US$ 0,004	≈ US$ 0,015
TOTAL ORIENTATIVO	≈ US$ 1,77	≈ US$ 6,62

Tarifas de referencia publicadas por AWS: Glue US$ 0,44 por DPU-hora; Athena US$ 5/TB escaneado; S3 Standard alrededor de US$ 0,023 por GB-mes en el primer tramo, sujetas a región, mínimos de facturación, políticas de créditos e impuestos. No contempla nuevas instancias EC2, NAT o RDS.

Mitigación de costos y observaciones

Mantener alertas AWS Budgets, reducir ejecuciones redundantes, revisar el tiempo real de Glue/Crawler, usar Parquet/particiones para minimizar escaneo y retirar recursos antiguos solo tras comprobar sus dependencias. La factura reportó NAT Gateway por 234 horas y otros gastos históricos; esos componentes no forman parte de la arquitectura documental de FraudCloud.

8. Seguridad, gobierno de datos y riesgos

CONTROL	IMPLEMENTACIÓN / ESTADO
Identidad	Acceso por IAM Identity Center; el conjunto administrativo temporal requiere reducir privilegios
MFA	Requerido por la consigna; evidencia específica de activación no disponible
S3	Bucket privado con Public Access Block; SSE-S3 (AES256) y bloqueo de tráfico sin TLS
Rol Glue	Permisos por prefijo sobre el bucket, más política AWSGlueServiceRole; revisar alcance real
Ciclo de vida	RAW 90 días; CURATED 180 días; resultados Athena 7 días
Athena	Workgroup con cifrado SSE-S3 y límite 1 GiB por consulta
Privacidad	Curated excluye edad precisa y población ciudad; RAW exige acceso restringido
Costos	AWS Budgets tiene alertas; no detiene automáticamente gastos

Riesgos y limitaciones

El dataset es procesado y se conoce por el archivo aportado, pero no se verificó su correspondencia byte a byte con la publicación declarada de Kaggle. No incluye moneda ni monto original; las relaciones por riesgo y horario son correlacionales. El panel es local. No se presenta prueba de MFA, simulación de IAM Policy o prueba de restauración; son verificaciones pendientes para una futura versión productiva. La estimación de la calculadora corresponde a un escenario con supuestos de uso; requiere ajustarse con métricas reales y volver a exportarse cuando cambie la carga.

Gestión responsable de la cuenta

La cuenta contenía EC2, RDS, NAT Gateways y direcciones IPv4 de prácticas previas. La revisión de rutas mostró dependencias en VPC antiguas; su eliminación requiere validación separada y no debe confundirse con la limpieza del stack de FraudCloud. Mantener el stack hasta la sustentación y eliminarlo de forma controlada al finalizar.

9. Conclusiones

• Se demuestra una arquitectura funcional de Big Data en AWS: CloudFormation completado, almacenamiento RAW/CURATED, Glue ETL SUCCEEDED, Crawler READY y consultas exitosas en Athena.

• Las 339 607 operaciones tienen una tasa observada global de fraude de 0,5247 %, con mayor incidencia nocturna y entre registros marcados high_risk_cat=1.

• Las tres consultas documentadas cumplen el mínimo de la rúbrica y entregan resultados coherentes con la validación local; se dispone además de ocho scripts SQL en el repositorio del proyecto.

• AWS Pricing Calculator exportó un escenario antes de descuentos por US$ 5,288387813 (≈ US$ 5,29), principalmente AWS Glue; no es un cargo real. Por separado, el importe neto de AWS Bills mostrado al 04/11/2026 fue US$ 0,00 en la vista de la cuenta. Los gastos de EC2, RDS y NAT de otros laboratorios no se asignan a FraudCloud.

• La seguridad técnica contempla bucket privado, cifrado y permisos de rol; como tarea pendiente conviene sustituir el acceso administrativo temporal por mínimo privilegio y acreditar MFA.

10. Referencias (formato IEEE)

[1] Curso Big Data y Cloud Computing, “Trabajo integrador: Big data y Cloud Computing”, consigna, 2026.

[2] D. B., “Credit Card Fraud Dataset”, Kaggle. https://www.kaggle.com/datasets/dhruvb2028/credit-card-fraud-dataset (fuente declarada; correspondencia exacta del CSV sin verificar).

[3] Amazon Web Services, “AWS Glue pricing”, https://aws.amazon.com/glue/pricing/, consultado nov. 2026.

[4] Amazon Web Services, “Amazon Athena pricing”, https://aws.amazon.com/athena/pricing/, consultado nov. 2026.

[5] Amazon Web Services, “Amazon S3 pricing”, https://aws.amazon.com/s3/pricing/, consultado nov. 2026.

[6] Amazon Web Services, “AWS Pricing Calculator”, https://calculator.aws/, consultado nov. 2026.

[7] Capturas reales de consola AWS, Athena, Glue, S3, Cost Explorer y Budgets, aportadas por el estudiante, 04-11-2026.

[8] AWS Pricing Calculator, “FraudCloud”, exportación CSV de 8 líneas, estado VALID, tarifas BEFORE_DISCOUNTS, 04-11-2026 17:00 (UTC-5). Archivo adjunto: FraudCloud_AWS_Pricing_Calculator_2026.csv.

Anexo. Evidencias válidas y descartes

Se entregan 14 capturas curadas en evidencias_seleccionadas/, un índice de procedencia y el CSV original de AWS Pricing Calculator (evidencia de costos modelados, no de facturación). Se excluyeron duplicados, pantallas del LMS, configuraciones fallidas de SSO, consultas vacías, errores corregidos y capturas de infraestructura anterior ajena al proyecto.